Fonti e stato delle tecnologie

Progetto Alveare – rete aperta di modelli IA specializzati Aggiornato a ottobre 2026. Raccoglie le fonti usate nelle analisi e valuta, per ogni area, quanto la tecnologia è pronta per il progetto.

Legenda della maturità

- **Pronta** – in uso reale, documentata, utilizzabile subito nel prototipo.
- **Utilizzabile** – funziona, ma con limiti noti o integrazione da fare.
- **Sperimentale** – risultati di ricerca o progetti giovani: da provare, non da cui dipendere.
- **Lacuna** – manca una soluzione matura; il progetto deve costruirla o aggirarla.

Sintesi

Area	Maturità	Tecnologie di riferimento
Esecuzione locale dei modelli	Pronta	llama.cpp, llama-swap, MLX
Modelli piccoli aperti per testo, traduzione, voce	Pronta	famiglie Qwen piccole, SmolLM3, Olmo 3, Hy-MT2, Kokoro, Whisper
Modelli di immagini a licenza aperta e loro compressione	Utilizzabile	FLUX.2 klein 4B, Qwen-Image-2512, Z-Image; SVDQuant/ Nunchaku
Inferenza distribuita su più dispositivi di casa	Utilizzabile	prima.cpp, exo
Scomposizione ed esecuzione parallela dei compiti	Utilizzabile	LLMCompiler; standard MCP e A2A
Router piccoli con confidenza	Utilizzabile	Needle (esempio); calibrazione isotonica
Fine-tuning su hardware domestico	Pronta	Unsloth (QLoRA), ai-toolkit, MLX distribuito
Training e validazione collaborativi	Utilizzabile/Sperimentale	Gradients, Templar/Gauntlet, Gensyn SAPO, Flower
Firma e verifica dei modelli	Pronta	OpenSSF Model Signing, firme Ed25519
Verifica dei risultati di nodi non fidati	Sperimentale per LLM, Lacuna per diffusion	TOPLOC
Compressione estrema (1–2 bit)	Sperimentale	BitNet b1.58, QAT ternario, AngelSlim
LLM a diffusione	Sperimentale	DiffusionGemma, LLaDA 2.0, Fast-dLLM
Launcher e distribuzione per non tecnici	Utilizzabile	Pinokio (modello di riferimento)
Valutazione privata e federata nei tornei	Lacuna	da costruire (prototipo: `alveare validate`)

1. Esecuzione locale dei modelli

Maturità: Pronta.

- **llama-swap** – proxy leggero (un binario e un file YAML) che espone un unico endpoint OpenAI-compatibile e avvia il server giusto in base al modello richiesto; supporta tempo di inattività per scaricare i modelli e profili per tenerne più d'uno attivo. Carica anche Whisper e stable-diffusion.cpp. Riferimenti: https://www.sourcepulse.org/projects/1775233, https://glukhov.org/it/llm-hosting/llama-swap/.

- **llama.cpp** – include anche una modalità router per gestire più modelli GGUF senza proxy separato (stessa fonte).
- **Raspberry Pi 5** – un modello da 1B (Gemma 3 1B) genera circa 10 token/s su un Pi 5 da 8 GB; in sola CPU ci si aspetta 5–15 token/s per modelli da 1,5B e 2–5 per modelli da 3B. Consumo: circa 3 W a riposo e fino a 8,8 W a pieno carico. Riferimenti: https://www.kunalganglani.com/blog/gemma-3-raspberry-pi-5-benchmark.md, https://tinyweights.dev/posts/run-llms-raspberry-pi-5/, https://raspberry.tips/en/faq/raspberry-pi-power-consumption-update-2026-all-models-compared.
- **Cactus engine** – motore MIT per dispositivi mobili; inferenza ibrida, modelli personalizzati e parte dell'accelerazione hardware sono a pagamento. Riferimento: https://cactuscompute.com/docs/v1.6.

Implicazione per il progetto. Il prototipo parla con i backend solo via API OpenAI-compatibile, così llama-server, llama-swap e vLLM restano intercambiabili.

---

2. Modelli aperti per i compiti del progetto

Maturità: Pronta per testo, traduzione e voce; Utilizzabile per immagini.

Testo – modelli completamente aperti (pesi, dati e codice)

- **Olmo 3** (7B e 32B), con catena di addestramento tracciabile fino ai dati. https://arxiv.org/html/2512.13961v2
- **SmolLM3-3B**, Apache-2.0, con miscela di dati pubblica. https://www.bentoml.com/blog/the-best-open-source-small-language-models
- **Apertus** (8B, 70B), dati aperti e oltre 1.800 lingue; i pesi della versione 1.5 sono ad accesso controllato. https://huggingface.co/swiss-ai/Apertus-70B-2509, https://huggingface.co/HackApertus

Traduzione

- **Hy-MT2** (Tencent): Apache-2.0, taglie 1,8B, 7B e 30B-A3B, 33 lingue; la versione da 1,8B compressa a 1,25 bit pesa circa 440 MB. https://www.orcarouter.ai/blog/north-small-translate-1-0-vs-tencent-hy-mt2

Voce

- **Kokoro** (82M parametri, Apache-2.0, supporta l'italiano). https://github.com/hexgrad/kokoro
- **Whisper / whisper.cpp** (MIT), gira fino al Raspberry Pi. https://d-central.tech/fr/modeles-ia-vocale-locale/

Immagini e editing – le licenze variano anche nella stessa famiglia:

- Apache-2.0: FLUX.2 [klein] 4B, Qwen-Image-2512, Z-Image, Qwen-Image-Edit-2509.
- Non commerciali: FLUX.2 [dev], FLUX.2 [klein] 9B, Qwen-Image-2.1 (passato da Apache-2.0 a licenza di sola ricerca). https://github.com/black-forest-labs/flux2/wiki, https://vdf.ai/blog/best-local-image-generation-models/, https://pinggy.io/blog/best_free_open_source_ai_image_generators_to_self_host/
- **Mobile**: SnapGen++ genera immagini 1024×1024 in circa 1,8 s su iPhone 16 Pro Max in 4 passi. https://the-decoder.com/snaps-snapgen-generates-high-resolution-ai-images-on-iphone-in-under-two-seconds/

Evidenze sui modelli piccoli specializzati

- Un modello sotto il miliardo di parametri, fine-tunato, supera modelli di frontiera usati senza esempi su nove benchmark di estrazione di relazioni. https://arxiv.org/html/2606.22606v1

- Un modello Qwen3.5 da 0,8B è in produzione al posto di modelli di frontiera per annotare la grammatica. https://arxiv.org/pdf/2610.10827
- Limite: nel coding reale i modelli piccoli fine-tunati restano molto sotto la frontiera. https://newsletter.systemdesign.one/p/fine-tuning-small-language-models

Implicazione. Accettare solo licenze OSI, fissare le versioni e archiviare i pesi: le licenze cambiano.

3. Inferenza distribuita su dispositivi di casa

Maturità: Utilizzabile.

- **prima.cpp** (ICLR 2026, MIT): modelli da 30–70B su gruppi di dispositivi domestici eterogenei, anche in Wi-Fi; 70B a circa 674 ms per token su quattro dispositivi, 32B a 26 token/s con decoding speculativo; latenza per token 5–17 volte più bassa di llama.cpp, exo e dllama. https://arxiv.org/abs/2504.08791, https://github.com/OpenCPIL/prima.cpp
- **exo**: dispositivi alla pari, scoperta automatica, suddivisione del modello in base alla topologia; percorso migliore oggi sui Mac (MLX). https://github.com/exo-explore/exo

Implicazione. Dividere un modello su più macchine serve dentro una LAN per far stare modelli grandi; tra reti diverse conviene parallelizzare per compito.

4. Scomposizione dei compiti, standard e router

Maturità: Utilizzabile.

- **LLMCompiler** (ICML 2024): pianificatore che costruisce un grafo di chiamate, smistamento ed esecuzione parallela; fino a 3,7× meno latenza e 6,7× meno costo rispetto a ReAct, anche con modelli aperti. https://arxiv.org/abs/2312.04511v2
- **MCP e A2A** sotto la governance neutrale dell'Agentic AI Foundation (Linux Foundation); le agent card A2A descrivono capacità e connessione di un agente. https://www.ai.engineer/orgs/agentic-ai-foundation, https://mcp.directory/blog/mcp-foundation-linux-foundation-aaif-2026-explained
- **Needle** (Cactus Compute) come esempio di router piccolissimo: 29–121M parametri, binario da 8–29 MB, pesi Apache-2.0, chiamate a strumenti con confidenza calibrata. Limiti: niente testo libero, al massimo 5 strumenti per turno, confidenza assente dopo il fine-tuning locale, poco affidabile fuori dall'inglese. https://cactuscompute.com/needle, https://cactuscompute.com/blog/needle-confidence, https://cactuscompute.com/blog/finetuning-needle, https://pypi.org/project/needle-rs/0.3.0/
- **Calibrazione della confidenza**: una regressione isotonica su un set di validazione ha ridotto l'errore di calibrazione da 0,12 a 0,03 in un caso di produzione. https://arxiv.org/pdf/2605.18796
- **OpenLLM (openllm.sh)**: buona idea di catene di riserva e dispositivi in rete, ma licenza Business Source 1.1, non open source OSI. https://glama.ai/mcp/servers/openllmsh/cli

5. Supporto alla conoscenza: indici, grafi, mappe

Maturità: Utilizzabile.

- **PageIndex**: indice gerarchico navigato dal modello, 98,7% su FinanceBench; richiede un modello capace di ragionare. https://pyshine.com/PageIndex-Vectorless-Reasoning-RAG/
- **LightRAG** (indice a grafo, recupero a due livelli) https://arxiv.org/pdf/2410.05779 e **MiniRAG** (pensato per modelli piccoli, circa 25% dello spazio) https://www.emergentmind.com/topics/minirag.

6. Compressione

Maturità: Pronta a 4 bit; Sperimentale sotto i 2 bit.

- **SVDQuant / Nunchaku**: diffusion a 4 bit; FLUX.1-dev occupa 3,6 volte meno memoria e su un laptop con 16 GB di GPU va fino a 8,7 volte più veloce; Qwen-Image scende a circa 3 GB di VRAM. https://arxiv.org/abs/2411.05007, https://github.com/nunchux-ai/nunchaku
- **Distillazione a pochi passi**: un LCM a 2–4 passi richiede circa 32 ore di A100; LCM-LoRA si applica a modelli già personalizzati e si combina con adattatori di stile. https://www.arxiv-vanity.com/papers/2311.05556
- **BitNet b1.58**: pesi ternari; il modello 2B4T è stato addestrato da zero su 4.000 miliardi di token (fuori portata per una community); bitnet.cpp accelera l'inferenza su CPU. https://labs.ai.azure.com/innovations/bitnet/, https://github.com/microsoft/BitNet
- **QAT ternario su piccola scala**: un modello di embedding a 1,58 bit mantiene circa il 95% della qualità e sta in 7 MB. https://huggingface.co/wenshutang/ternlight

7. LLM a diffusione

Maturità: Sperimentale.

- DiffusionGemma (Apache-2.0, giugno 2026) e LLaDA 2.0 (16B e 100B, pesi aperti). https://zylos.ai/research/2026-06-16-diffusion-language-models-agentic-inference/
- Fast-dLLM: fino a 27,6 volte più throughput su LLaDA e Dream. https://nvlabs.github.io/Fast-dLLM/
- Fast-dLLM v2 converte un modello autoregressivo in uno a diffusione con circa un miliardo di token di fine-tuning. https://buzzgrewal.medium.com/beyond-next-token-how-diffusion-llms-like-mercury-2-and-llada-hit-1-000-tokens-per-second-in-2026-996b52cd4fce

8. Training su hardware domestico

Maturità: Pronta.

- **Unsloth**: QLoRA di un modello da 8B in circa 6 GB di VRAM, da 3B in circa 3,5 GB. https://docs.unsloth.ai/get-started/beginner-start-here/unsloth-requirements
- **Adattatori per immagini**: AI Toolkit chiede almeno 24 GB per FLUX e Qwen-Image, 32 GB o più per i modelli di editing; con pesi FP8 bastano 12 GB e 3–5 ore per 20–50 immagini. https://www.runcomfy.com/

trainer/ai-toolkit/getting-started, https://www.promptus.ai/workflow/how-to-train-lora-models-with-flux-in-comfyui

- **Più Mac insieme**: mlx_lm.lora supporta il fine-tuning distribuito; su Thunderbolt circa 20 Gbps effettivi per collegamento. https://developer.apple.com/videos/play/wwdc2026/233/, https://arxiv.org/pdf/2609.18066

9. Training e validazione collaborativi

Maturità: Utilizzabile (tornei, federato); Sperimentale (training sincrono via internet).

- **Gradients** (torneo di fine-tuning): 10–20 partecipanti per modelli linguistici e 15–25 per diffusion, valutazione su test segreti; ha battuto TogetherAI, Databricks e Google Cloud nel 100% dei casi e AutoTrain nell'82,8%; si appoggia a un validatore principale gestito da Rayon Labs. https://arxiv.org/abs/2506.07940v1, https://learnbittensor.org/subnets/56
- **Templar / Gauntlet**: training permissionless; i validatori misurano quanto ogni contributo riduce l'errore. https://arxiv.org/html/2505.21684v1
- **Gensyn SAPO / RL Swarm**: apprendimento per rinforzo condiviso tra nodi eterogenei, fino a +94% di ricompensa cumulativa; codice MIT. https://arxiv.org/abs/2509.08721v1, https://blog.gensyn.ai/rl-swarm-a-framework-for-collaborative-rl/
- **Rischio di attacchi** nel training decentralizzato documentato dalla stessa Gensyn. https://www.gensyn.ai/research/sapo-efficient-lm-post-training-with-collective-rl
- **Flower / FlowerTune**: fine-tuning federato con LoRA senza condividere i dati (NeurIPS 2025). https://proceedings.neurips.cc/paper_files/paper/2025/hash/563991b5c8b45fe75bea42db738223b2-Abstract-Datasets_and_Benchmarks_Track.html
- **Training via internet su larga scala**: INTELLECT-1 (10B su 1.000 miliardi di token) https://arxiv.org/pdf/2412.01152; anche i modelli più grandi addestrati così hanno usato circa mille volte meno calcolo della frontiera https://epoch.ai/gradient-updates/how-far-can-decentralized-training-over-the-internet-scale.

Lacuna. Non esiste uno standard maturo per la valutazione privata e federata dei candidati: il prototipo ne implementa una prima versione (rapporto firmato con solo l'hash dei casi di test).

10. Fiducia e sicurezza

Maturità: Pronta per la firma dei modelli; Sperimentale per la verifica dei risultati.

- **OpenSSF Model Signing (OMS)**: supporta Sigstore, certificati auto-firmati o coppie di chiavi con lo stesso formato; NVIDIA firma i modelli su NGC da marzo 2025; la variante Sigstore senza chiavi richiede la rete. https://openssf.org/?p=8454, https://tianpan.co/blog/2026/07/02/sign-your-weights, https://pypi.org/project/modelsign/1.0.2/
- **TOPLOC**: verifica che un nodo non fidato abbia usato il modello, il prompt e la precisione dichiarati, con 258 byte di prova ogni 32 token; integrato con vLLM e SGLang. https://primeintellect.ai/blog/toploc, https://proceedings.mlr.press/v267/ong25a.html

Lacuna. Per i modelli diffusion non risulta un metodo maturo equivalente: proposta di riesecuzione a campione con confronto percettivo, da validare.

11. Community, volontariato, distribuzione

- **AI Horde**: rete non-profit di GPU volontarie per immagini e testo, con crediti non commerciabili; oltre 135 milioni di richieste testuali evase, ma poche decine di worker attivi in un dato momento. https://stablehorde.net:443, https://aihorde.net/contribute/joining
- **OpenAssistant**: oltre 13.000 volontari, più di 625.000 compiti completati, dati con licenze permissive. https://arxiv.org/pdf/2304.07327
- **Pinokio**: launcher MIT per installare app di IA in un clic, script JSON/JavaScript con variabili sull'hardware rilevato; nessun ricavo. https://pasqualepillitteri.it/en/news/9050/pinokio-ai-browser-install-guide, https://thegtmdirectory.com/tools/pinokio

12. Dati di mercato e d'uso (analisi delle potenzialità)

Dato	Valore	Fonte
Quota di richieste di lavoro che riguardano la scrittura	40% (due terzi modificano un testo dato)	https://cdn.openai.com/pdf/a253471f-8260-40c6-a2cc-aa93fe9f142e/economic-research-chatgpt-usage-paper.pdf
Quota di messaggi sulla programmazione	4,2%	stessa fonte
Imprese italiane (≥ 10 addetti) che usano IA	16,4% nel 2025	https://www.istat.it/comunicato-stampa/imprese-e-ict-anno-2025/
Imprese italiane che hanno valutato l'IA senza adottarla	11,5%	https://www.assolombarda.it/centro-studi/utilizzo-dellintelligenza-artificiale-nelle-imprese
Barriere tra le imprese UE che hanno valutato l'IA	competenze 70,3%, incertezza legale 53,6%, privacy 52,7%	https://ai.bcci.bg/en/news/why-companies-that-considered-ai-decided-against-it
Mercato italiano dell'IA	1,8 miliardi € nel 2025	https://www.borsaitaliana.it/borsa/notizie/teleborsa/economia/l-ai-vale-18-miliardi-in-italia-al-via-confronto-alla-camera-su-pmi-e-competenze-103_2026-09-25_TLB.html
Costo orario del lavoro in Italia	30,9 € (2024)	https://tg24.sky.it/economia/2025/04/10/lavoro-costo-orario-paesi-ue
Effetto dell'IA generativa sulla produttività	+14% medio, +34% per i meno esperti	https://www.nber.org/papers/w31161
Prezzi API (per milione di token)	Opus 5.5: 4 $ / 20 $; DeepSeek V4.1 Flash: 0,30 $ / 1,20 $ (punta)	https://www.gradually.ai/en/llm-comparison/claude-opus-5.5-vs-deepseek-v4.1-flash/
Calo dei prezzi a parità di prestazioni	mediana 50× all'anno, 200× dal 2024	https://epoch.ai/data-insights/llm-inference-price-trends
Ritardo dei modelli aperti su GPU consumer rispetto alla frontiera	un anno o meno	https://epoch.ai/blog/top-10-data-insights-and-gradient-updates-of-2025
PC da gioco con almeno 10 GB di VRAM	51,4% (luglio 2026)	https://tbreak.com/steam-hardware-survey-16gb-vram-overtakes-8gb/
Struttura delle imprese italiane	4,37 milioni di imprese, 94,9% sotto i 10 addetti (dato 2010)	https://www.istat.it/it/archivio/73481

13. Lacune principali da colmare con il progetto

1. **Valutazione privata e federata** dei candidati nei tornei, resistente alla manipolazione.
2. **Verifica dei risultati dei modelli diffusion** prodotti da nodi non fidati.

3. **Router piccoli affidabili in italiano**, con confidenza calibrata dopo il fine-tuning.
4. **Launcher per non tecnici** che nasconda chiavi, firme e configurazioni.
5. **Incentivi senza token** capaci di mantenere una partecipazione stabile.