DOCUMENTO DI SINTESI · OTTOBRE 2026

Alveare

Una rete aperta di modelli IA specializzati: addestrati insieme dalla community, usati in reti locali completamente offline

≈ 27%	≈ 13.500	≈ 7.350 €	< 10 €
delle richieste di lavoro trasformano un testo dato	imprese italiane frenate dalla privacy (stima)	valore annuo per una PMI da 10 persone (stima)	di elettricità per ciclo di miglioramento

1. Il problema

Oggi l'IA generativa di qualità arriva quasi sempre da servizi chiusi raggiungibili via API. Per molte organizzazioni questo è un ostacolo: in Europa, tra le imprese che hanno valutato l'IA senza adottarla, il **52,7%** indica i timori sulla protezione dei dati, il **53,6%** l'incertezza legale e il **70,3%** la mancanza di competenze (Eurostat 2025). In Italia l'IA è usata dal 16,4% delle imprese con almeno 10 addetti, e un ulteriore 11,5% l'ha valutata senza adottarla (Istat 2025).

Esistono però modelli aperti piccoli e capaci, che specializzati su un compito preciso raggiungono i modelli di frontiera su quel compito, e strumenti maturi per eseguirli su hardware comune. Manca il pezzo che li mette insieme: un modo condiviso per **specializzarli**, **verificarli** e **usarli senza internet**.

2. L'idea in breve

Alveare (nome di lavoro) è un sistema in due livelli separati, collegati da un solo canale a senso unico.

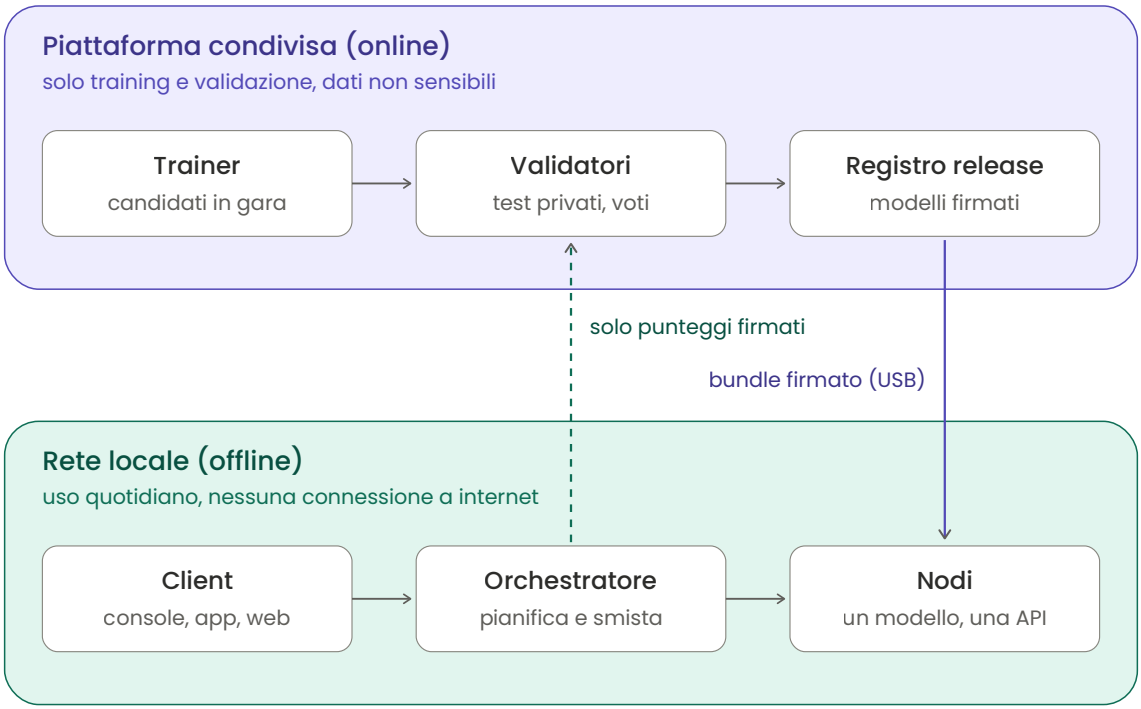
Piattaforma condivisa – online

La community sceglie un modello aperto e lo specializza per un compito (riassunto, traduzione, correzione, estrazione, voce, immagini). Chi ha una GPU addestra candidati in gara; chi ha qualsiasi dispositivo fa da **validatore** con i propri test privati. Più utenti sono interessati a un compito, più test e più validazioni arrivano: il modello migliora e viene pubblicato come **bundle firmato**.

Rete locale – offline

Orchestratore, nodi e client in una LAN scollegata da internet. Ogni nodo espone uno o più compiti come API, a discrezione dell'amministratore. L'orchestratore scompone le richieste in passi e li esegue **in parallelo** sui nodi. I modelli entrano solo come bundle firmati, portati su supporto rimovibile e verificati prima dell'uso.

3. Architettura



I modelli entrano nella rete locale come bundle firmati; dalla rete locale può uscire, solo se l'utente lo decide, un rapporto di punteggio firmato che contiene il risultato dei test ma non i test.

Ruolo	Cosa fa	Hardware tipico
Orchestratore	interpreta la richiesta, sceglie o costruisce la ricetta (grafo di passi), smista i passi ai nodi, assembla il risultato	mini-PC o PC con 16–32 GB
Nodo	espone compiti come API; ogni compito = un bundle verificato + un motore locale (llama.cpp)	PC, laptop, Raspberry Pi 5
Client	invia documenti e richieste; può essere anche nodo	qualsiasi
Validatore	esegue test privati sui candidati e firma il punteggio; funziona anche offline	qualsiasi
Trainer	addestra candidati in gara (adattatori LoRA, distillazione, compressione)	GPU da 8–24 GB

4. Come funziona la piattaforma condivisa

Torneo, non training sincrono. Ogni partecipante addestra il proprio candidato sulla propria GPU, senza sincronizzarsi con gli altri; vince il migliore e la sua ricetta di training diventa pubblica, punto di partenza del round successivo. È lo schema di Gradients, che in un confronto su 180 compiti ha battuto TogetheRAI, Databricks e Google Cloud nel 100% dei casi.

Validazione con test privati. Il punto delicato dei tornei è il test segreto: chi lo custodisce deve essere fidato. Alveare lo distribuisce: ogni validatore tiene i propri casi di test, esegue i candidati sulla propria macchina e firma solo il punteggio con l'hash dei casi. I punteggi si aggregano con la mediana, scartando quelli non firmati.

Release firmate. Il vincitore viene firmato con la chiave del progetto (formato compatibile con OpenSSF Model Signing tramite coppie di chiavi, verificabili offline) e pubblicato nel registro e nel pacchetto per supporti rimovibili. Solo licenze approvate OSI.

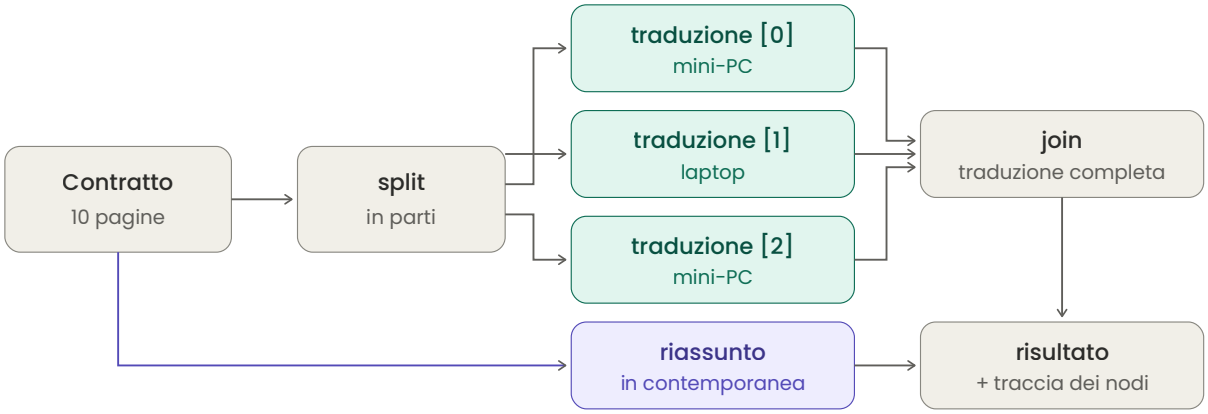
5. Come funziona la rete locale

- **Import verificato:** chiave fidata, firma, hash e dimensione di ogni file, licenza ammessa. Se qualcosa non torna, il compito resta disabilitato.
- **Un compito, una API:** l'amministratore decide quali compiti espone ogni nodo e quali postazioni possono usarli, con chiavi API conservate solo come hash.
- **Ricette parallele:** l'orchestratore esegue i passi appena le loro dipendenze sono pronte, sceglie il nodo meno carico e, se un nodo fallisce, riprova su un altro.
- **Offline per costruzione:** ogni indirizzo configurato deve appartenere alla rete locale; un indirizzo pubblico impedisce l'avvio.

6. Esempio d'uso: uno studio professionale

Uno studio di consulenza con 10 persone tratta contratti di clienti che non possono uscire dall'ufficio. Installa Alveare su tre macchine che possiede già: un mini-PC (orchestratore e nodo con traduzione e riassunto), un laptop (secondo nodo di traduzione) e un Raspberry Pi 5 (correzione di testi brevi). La LAN non ha collegamento a internet.

Un collaboratore carica un contratto di 10 pagine e sceglie "*Traduci in inglese e riassumi*". L'orchestratore divide il testo in parti, le traduce in parallelo sui due nodi e, nello stesso momento, produce il riassunto in italiano:



Nel prototipo, con un motore simulato che impiega 0,4 secondi per chiamata, questa ricetta completa quattro chiamate in circa 0,7 secondi invece dei 2,6 che servirebbero in sequenza (guadagno di circa 3,8 volte). Con modelli veri i tempi dipendono dall'hardware, ma il principio è lo stesso: più nodi, più parti in parallelo.

Lo studio partecipa anche al miglioramento dei modelli senza esporre nulla: quando esce un nuovo candidato per il riassunto, lo prova con 50 casi tratti dal proprio lavoro e invia soltanto il punteggio firmato. Al rilascio successivo importa il nuovo bundle da una chiavetta USB.

7. Potenzialità in numeri

Stime d'ordine di grandezza basate su dati pubblici; le ipotesi sono indicate. Per semplicità 1 $ ≈ 1 €.

Grandezza	Calcolo	Risultato
Domanda coperta da modelli specializzati	40% delle richieste di lavoro riguarda la scrittura × 2/3 modifica un testo dato (studio NBER/OpenAI)	**≈ 27%** delle richieste di lavoro
Costo per richiesta (2.000 token in, 500 out)	Opus 5.5: 0,018 $ · DeepSeek V4.1 Flash: 0,0012 $ · locale: ≈ 0,0002 € di elettricità	il locale vince sul costo solo con hardware già posseduto
Costo annuo PMI (11.000 richieste/mese)	Opus 5.5 ≈ 2.376 $ · DeepSeek ≈ 158 $ · mini-PC nuovo ≈ 1.190 € · PC già posseduto ≈ 58 €	il valore non è il risparmio sui token
Valore di produttività per PMI da 10 persone	10 × 1.700 h × 10% su compiti di testo × 14% di guadagno × 30,9 €/h	**≈ 7.350 €/anno** (ritorno ≈ 6×)
Imprese italiane frenate dalla privacy	≈ 223.000 imprese con ≥ 10 addetti × 11,5% × 52,7%	**≈ 13.500**
Valore annuo con adozione 1% / 5% / 15%	imprese adottanti × 7.350 €	≈ 1 / 5 / 15 milioni €
Costo di un round di torneo	15 candidati × 5 h × 0,35 kW × 0,326 €/kWh	**≈ 9 €**
Volontari per un dataset di 2.500 esempi	ritmo di OpenAssistant: ≈ 46 compiti per volontario	**≈ 54**

Scenari di capacità della community (15 candidati per round, 5 round al mese):

Scenario	Trainer attivi	Progetti in parallelo	Cicli di miglioramento/anno	Volontari per i dati
Pessimistico (simile ad AI Horde)	30	2	≈ 120	≈ 110
Base	300	20	≈ 1.200	≈ 1.100
Ottimistico (scala OpenAssistant)	3.000	200	≈ 12.000	≈ 10.800

Lettura. Il potenziale è reale ma di nicchia: lo scenario ottimistico vale circa lo 0,8% del mercato italiano dell'IA (1,8 miliardi € nel 2025). Il valore non sta nel risparmio sui token, perché i prezzi delle API calano in mediana di 50 volte all'anno a parità di prestazioni, ma nello **sbloccare l'uso dell'IA dove oggi è vietato o temuto**.

8. Cosa serve perché funzioni

Condizioni decisive

- **Volontari per i dati:** l'elettricità costa pochi euro, i dati curati a mano no. È il vincolo che decide lo scenario.
- **Semplicità del launcher:** la mancanza di competenze blocca più della privacy; l'installazione deve richiedere meno di 30 minuti a chi non è tecnico.
- **Licenze stabili:** solo pesi OSI, versioni fissate e archiviate.

Rischi principali

- Partecipazione bassa senza incentivi economici.
- Manipolazione dei punteggi nei tornei.
- Prestazioni dei modelli piccoli in italiano da verificare compito per compito.
- Software di terze parti che tenta connessioni in uscita.

9. Stato e prossimi passi

Esiste già un **prototipo funzionante della rete locale** (Python, Apache-2.0): bundle firmati e verificati, registro locale, nodi con agent card ispirata ad A2A, orchestratore con ricette parallele e nuovo tentativo su altro nodo, politica di rete solo LAN, validazione locale con rapporto firmato. 28 test superati e demo completa con processi reali.

Settimane	Fase	Risultato
1	Fondamenta	repository pubblico con integrazione continua
2–4	Rete con modelli veri	demo offline con 3 compiti reali, installazione senza internet
4–5	Catena di fiducia	aggiornamenti da USB, revoca, firma OMS
6–8	Orchestratore intelligente	richieste in linguaggio naturale, conferme
6–10	Primo modello specialistico	bundle firmato che batte il modello base
10–14	Pilota della piattaforma	primo torneo con release pubblica
12–16	Launcher e pilota	uso reale in 1–3 organizzazioni

Fonti principali

1. Chatterji et al., *How People Use ChatGPT*, NBER/OpenAI 2025 – quote d'uso (scrittura 40% del lavoro, coding 4,2%).
2. Istat, *Imprese e ICT – anno 2025*; Assolombarda – adozione dell'IA e imprese che l'hanno valutata.
3. Eurostat 2025 (isoc_eb_ai) – barriere all'adozione dell'IA tra le imprese che l'hanno valutata.
4. Brynjolfsson, Li, Raymond, *Generative AI at Work*, QJE 2025 – +14% di produttività.
5. Eurostat – costo orario del lavoro 2024 (Italia 30,9 €).
6. Osservatorio Artificial Intelligence, Politecnico di Milano – mercato italiano dell'IA 2025.
7. Epoch AI – andamento dei prezzi di inferenza; ritardo dei modelli aperti su GPU consumer.
8. Subia-Waud, *Gradients: When Markets Meet Fine-tuning*, 2025 – tornei di fine-tuning.
9. Köpf et al., *OpenAssistant Conversations*, NeurIPS 2023 – volontariato sui dati.
10. AI Horde – rete volontaria di GPU con crediti non commerciabili.
11. OpenSSF Model Signing; Prime Intellect, TOPLOC – firma e verifica.
12. Li et al., *prima.cpp*, ICLR 2026; Kim et al., *LLMCompiler*, ICML 2024.
13. Prezzi API: Opus 5.5 e DeepSeek V4.1 Flash (ottobre 2026); report "IA in locale a ottobre 2026" per hardware e consumi.

L'elenco completo con i link e la valutazione dello stato delle tecnologie è nel documento “Fonti e stato delle tecnologie”.